Laporan Tugas Besar 1

IF4071 - Pemrosesan Ucapan

Pengumpulan Korpus Suara Bahasa Daerah Indonesia



Disusun Oleh

Danendra Shafi Athallah 13523136

Jonathan Kenan Budianto 13523139

Jovandra Otniel Pangalambok Siregar 13523141

Muhammad Farrel Wibowo 13523153

Lukas Raja Agripa 13523158

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

2026

DAFTAR ISI

DAFTAR ISI **2**

1. Pendahuluan **3**

1.1. Tujuan Pengumpulan Korpus 3

1.2. Bahasa/Dialek dan Penggunaan Korpus 3

2. Perancangan Korpus **4**

2.1. Spesifikasi Korpus 4

2.2. Karakteristik dan Distribusi Penutur 5

2.3. Topik dan Durasi Rekaman 6

2.4. Format Audio, Metadata, dan Skema Anotasi 7

3. Proses Pengumpulan Korpus **8**

3.1. Pemilihan Penutur 8

3.2. Persiapan dan Proses Perekaman 9

3.3. Pengelolaan Berkas Audio 10

4. Hasil dan Quality Control **11**

4.1. Hasil Pengumpulan Rekaman 11

4.2. Dokumentasi Hasil Quality Control 12

4.3. Hasil Anotasi dan Review 15

5. Penutup **17**

5.1. Kesimpulan 17

REFERENSI **19**

1. Pendahuluan

1.1. Tujuan Pengumpulan Korpus

Korpus ini dikumpulkan untuk memenuhi Tugas Besar IF4071 Pemrosesan Ucapan Fase 1, yaitu membuat korpus suara bahasa daerah sebagai data untuk membangun sistem pengenal ucapan pada Fase 2. Kelompok memilih Bahasa Jawa sebagai bahasa yang dikumpulkan.

Sasaran pengumpulan adalah ucapan spontan dari 10 penutur, terdiri atas 5 laki-laki dan 5 perempuan, dengan durasi sekitar 10–15 menit per penutur atau sekitar 100–150 menit secara keseluruhan. Setiap rekaman dilengkapi metadata, label kualitas, dan anotasi berupa transkripsi serta label lain sesuai kebutuhan.

Pada saat laporan ini disusun, rekaman audio, metadata, label kualitas, dan anotasi tersedia untuk 10 penutur (S01–S10). Rekapitulasi metadata dan *quality control* (QC) dalam laporan ini karenanya mencakup kesepuluh penutur.

1.2. Bahasa/Dialek dan Penggunaan Korpus

Bahasa yang menjadi fokus korpus adalah Bahasa Jawa (kode ISO 639-1 jv). Seluruh sepuluh baris metadata.csv mencatat bahasa sebagai “Jawa” tanpa dialek. Dialek tercatat pada berkas anotasi, yang memuat label dialek untuk kesepuluh penutur: Jawa Timuran untuk empat penutur (S01, S07, S08, S10), Jawa Tengahan atau Mataraman untuk lima penutur (S02, S03, S04, S05, S06), dan Jawa campuran Tengahan–Malangan untuk satu penutur (S09). Korpus ini dengan demikian memuat lebih dari satu dialek. Tidak seluruh ucapan berbahasa Jawa, karena anotasi juga memuat segmen berbahasa Indonesia, Inggris, dan campuran (Subbab 4.3).

Korpus akan dipakai sebagai data untuk mengembangkan sistem pengenal ucapan Bahasa Jawa pada Fase 2, yaitu untuk *training*, *validation*, dan *testing* sesuai rancangan kelompok. Seluruh berkas disimpan di repositori GitHub

kelompok (https://github.com/rlukassa/Korpus_Bahasa_Jawa) agar dapat diakses dosen, asisten, dan mahasiswa lain.

2. Perancangan Korpus

2.1. Spesifikasi Korpus

Tabel 2.1 memuat spesifikasi korpus yang ditetapkan pada spesifikasi tugas Fase 1. Tabel ini hanya menyajikan ketentuan. Kondisi aktual korpus dibahas pada Subbab 2.2 sampai 2.4 dan pada Bab 4.

Tabel 2.1. Spesifikasi korpus

Aspek	**Ketentuan**
Bahasa	1 bahasa daerah per kelompok (kelompok ini: Bahasa Jawa)
Jumlah penutur	10 orang
Gender	5 laki-laki dan 5 perempuan
Jenis ucapan	*Spontaneous speech* / *conversation*
Topik	Minimal 3 topik
Durasi	Sekitar 10–15 menit per penutur
Sampling rate	16 kHz
Bit depth	16-bit
Channel	Mono
Format	WAV
Lingkungan	*Indoor*, relatif tenang
Metadata	Wajib (metadata.csv)
Quality control	Label Good / Acceptable / Reject; berkas Reject direkam ulang jika memungkinkan
Anotasi	Transkripsi dan label sesuai kebutuhan, dilanjutkan dengan *review*

Selain ketentuan pada tabel, spesifikasi tugas meminta setiap kelompok mengumpulkan satu folder korpus yang berisi audio WAV, metadata.csv, berkas anotasi, dokumentasi hasil QC, README korpus, dan laporan singkat proses pengumpulan.

2.2. Karakteristik dan Distribusi Penutur

Spesifikasi tugas meminta 10 penutur dengan komposisi 5 laki-laki dan 5 perempuan, serta pencatatan Speaker ID, bahasa/dialek, daerah asal, dan latar belakang penggunaan bahasa tiap penutur. Rancangan kelompok menambahkan kriteria bahwa penutur adalah penutur asli (L1) Bahasa Jawa berusia minimal 18 tahun. Rentang usia dan dialek utama belum ditetapkan pada rancangan tersebut.

Tabel 2.2 menunjukkan kesepuluh Speaker ID yang memiliki rekaman. Kolom gender bersumber dari metadata.csv, sedangkan label dialek bersumber dari berkas anotasi.

Tabel 2.2. Penutur yang memiliki rekaman

Speaker ID	Gender	Label dialek pada anotasi
S01	M	Jawa Timuran (Suroboyoan)
S02	M	Jawa Tengahan (Semarangan)
S03	M	Jawa Tengahan (Solo); penutur non-asli
S04	M	Jawa Mataraman (Jogja); 2 segmen ragam krama
S05	M	Jawa Tengahan/Mataraman (ngoko); penutur warisan
S06	F	Jawa Tengahan (Semarangan)
S07	F	Jawa Timuran (Suroboyoan)
S08	F	Jawa Timuran (Suroboyoan)
S09	F	Jawa campuran (Tengahan + Malangan); penutur non-asli
S10	F	Jawa Timuran (Trenggalekan/Mataraman wetan)

Menurut metadata.csv, lima penutur berjenis kelamin laki-laki (S01–S05) dan lima penutur perempuan (S06–S10), sehingga komposisi 5 laki-laki dan 5 perempuan sesuai spesifikasi.

Tiga penutur diberi label yang tidak sejalan dengan kriteria penutur asli pada rancangan kelompok: S03 dan S09 berlabel penutur non-asli (*non-native*), dan S05 berlabel penutur warisan. Status ini perlu dikonfirmasi kelompok, termasuk keputusan apakah rekaman ketiganya tetap digunakan. Daerah asal, rentang

usia, dan latar belakang penggunaan bahasa seluruh penutur belum terdokumentasi pada berkas yang tersedia.

2.3. Topik dan Durasi Rekaman

Spesifikasi tugas memberi tujuh contoh topik dan mewajibkan minimal tiga topik. Kelompok memberi kode global T01–T07 pada ketujuh topik tersebut. Pada pelaksanaannya, kelompok tidak merekam tiap topik secara terpisah. Setiap penutur direkam dalam satu sesi yang mencakup empat topik sekaligus, yaitu Perkenalan, Aktivitas sehari-hari, Pendidikan, dan Makanan, sehingga satu berkas rekaman memuat keempat topik tersebut. Rekaman gabungan ini diberi kode T01, sehingga nama berkas seluruh penutur berpola Sxx_T01_001.wav. Dengan demikian, T01 pada nama berkas berarti rekaman gabungan empat topik, bukan topik Perkenalan saja.

Penutur menjawab 15 pertanyaan panduan yang dikelompokkan menurut keempat topik tersebut, dengan total durasi jawaban 10–15 menit per penutur. Tabel 2.3 memuat topik, kode globalnya, dan pertanyaan panduan tiap topik. Sesuai rancangan kelompok, penutur menjawab dengan kalimatnya sendiri tanpa naskah jawaban.

Tabel 2.3. Topik pada rekaman T01 dan pertanyaan panduannya

Topik	Pertanyaan panduan
Perkenalan	Kamu berasal dari daerah mana, dan seperti apa suasana di sana? Sifat-sifat apa yang mendeskripsikan Anda, dan mengapa? Hobi apa yang Anda miliki? Coba jelaskan. Ceritakan bagaimana Anda di masa SD, SMP, dan SMA.
Aktivitas sehari-hari	Ceritakan kegiatan keseharian Anda. Hari apa yang paling menyenangkan dalam seminggu, dan mengapa? Kalau sedang libur, biasanya kamu melakukan apa saja?
Pendidikan	Anda kuliah di mana dan jurusan apa? Mengapa memilih kuliah dan jurusan tersebut? Apa saja yang Anda lakukan semasa kuliah? Ceritakan teman-teman dekat Anda di kuliah. Apa satu kejadian paling mengesankan yang Anda ingat semasa kuliah?

Topik	Pertanyaan panduan
Makanan	Makanan apa yang paling kamu suka, dan mengapa? Coba jelaskan. Makanan apa yang tidak kamu suka, dan mengapa? Coba jelaskan. Kalau makan, kamu lebih suka menggunakan tangan atau sendok/garpu? Mengapa? Ceritakan makanan khas daerahmu yang menurutmu wajib dicoba.

Kolom Topic pada metadata.csv di kesepuluh baris berisi "Perkenalan; Keluarga; Aktivitas sehari-hari; Makanan". Isi ini berbeda dari pertanyaan panduan pada Tabel 2.3: Keluarga tercatat pada metadata tetapi tidak ada pertanyaan tentang keluarga, sedangkan Pendidikan ada pada pertanyaan tetapi tidak tercatat. Berkas anotasi sejalan dengan pertanyaan panduan. Berkas annotation-semua.csv memiliki 16 label topik, yaitu satu label untuk tiap pertanyaan (misalnya Asal daerah & suasana, Hobi, Kuliah & jurusan, dan Makanan khas daerah) ditambah label Penutup, dan tidak ada label Keluarga. Kolom Topic pada metadata perlu dikoreksi menjadi "Perkenalan; Aktivitas sehari-hari; Pendidikan; Makanan". Kesesuaian isi audio dengan pertanyaan panduan belum diverifikasi dalam penyusunan laporan ini.

Durasi yang ditetapkan adalah sekitar 10–15 menit per penutur untuk seluruh pertanyaan pada keempat topik. Rancangan kelompok menafsirkan durasi ini sebagai ucapan bersih, yaitu durasi setelah bagian yang tidak terpakai dipotong. Durasi kesepuluh berkas berkisar antara 600,00 dan 701,67 detik (10,00–11,69 menit). Angka tersebut adalah durasi berkas, bukan durasi ucapan bersih. Rinciannya disajikan pada Subbab 4.1.

2.4. Format Audio, Metadata, dan Skema Anotasi

Spesifikasi menetapkan format audio WAV dengan *sampling rate* 16 kHz, *bit depth* 16-bit, dan *channel* mono. Tabel 2.4 membandingkan ketentuan tersebut dengan hasil pemeriksaan teknis terhadap kesepuluh berkas WAV yang tersedia, menggunakan ffprobe.

Tabel 2.4. Format audio: ketentuan dan hasil pemeriksaan teknis

Aspek	Ketentuan	Hasil pemeriksaan
Format berkas	WAV	WAV (ekstensi .wav)
Kodek	PCM *signed* 16-bit *little-endian* (rancangan kelompok)	pcm_s16le pada 10 dari 10 berkas
Sampling rate	16 kHz	16000 Hz pada 10 dari 10 berkas
Bit depth	16-bit	16-bit pada 10 dari 10 berkas
Channel	Mono	1 *channel* pada 10 dari 10 berkas

Pemeriksaan ini hanya menyangkut format dan tidak menunjukkan kualitas rekaman. Kualitas dibahas pada Subbab 4.2.

Spesifikasi mewajibkan satu berkas metadata.csv dengan delapan kolom minimal: File, Speaker, Gender, Language/Dialect, Topic, Duration, Environment, dan Quality. Rancangan kelompok menambahkan kolom opsional seperti Session, Start, End, SpeechType, Register, Device, OrigSampleRate, RecordingDate, Recorder, Problem, dan Split. Pada implementasi, metadata.csv berisi sepuluh baris (S01–S10), satu per berkas WAV, dengan delapan kolom wajib dan tanpa kolom tambahan. Kolom keempat bernama Language, bukan Language/Dialect. Nilai Duration pada setiap baris berselisih kurang dari 0,01 detik dari durasi berkas hasil ffprobe.

Spesifikasi meminta anotasi minimal berupa transkripsi, label speaker, label bahasa/dialek, label topik, dan label kejadian khusus seperti *noise*, *overlap*, dan *laughter*. Anotasi kemudian direview melalui alur Audio → Annotation → Review → Perbaikan → Final Annotation. Rancangan kelompok menuangkan anotasi dalam satu berkas CSV dengan kolom File, Speaker, Start, End, Transcription, Language/Dialect, Register, Topic, Events, Annotator, Reviewer, dan Status (draft, reviewed, final), dengan Reviewer berbeda dari Annotator.

Pada implementasi, anotasi berada dalam berkas annotation-semua.csv dengan kolom file, segment_id, start, end, durasi_detik, transkripsi, label_speaker, label_bahasa, label_dialek, label_topik, label_kejadian, dan

confidence_asr. Berkas ini memuat segmentasi per ucapan, label dialek, dan skor kepercayaan ASR, tetapi tidak memuat kolom Annotator, Reviewer, Status, maupun Register.

3. Proses Pengumpulan Korpus

3.1. Pemilihan Penutur

Spesifikasi tugas meminta pemilihan 10 penutur dengan komposisi 5 laki-laki dan 5 perempuan. Informasi yang dicatat untuk tiap penutur meliputi Speaker ID, bahasa/dialek, daerah asal, dan latar belakang penggunaan bahasa. Kriteria dalam rancangan kelompok adalah penutur asli Bahasa Jawa berusia minimal 18 tahun. Spesifikasi juga membagi tanggung jawab sehingga setiap anggota kelompok menangani dua penutur.

Penutur diidentifikasi dengan Speaker ID S01 sampai S10. Rancangan kelompok menetapkan bahwa nama asli dan kontak penutur disimpan di luar repositori, dan repositori hanya memuat Speaker ID. Laporan ini mengikuti ketentuan tersebut dan tidak memuat identitas pribadi penutur.

Rekaman sudah tersedia untuk kesepuluh Speaker ID. Dialek penutur dicatat pada berkas anotasi (Tabel 2.2), dan tiga penutur diberi label non-asli atau warisan. Proses seleksi aktual, yaitu cara penutur dipilih, anggota kelompok yang menangani tiap penutur, serta daerah asal dan usia penutur, tidak terdokumentasi pada berkas yang tersedia dan perlu dikonfirmasi kelompok.

3.2. Persiapan dan Proses Perekaman

Spesifikasi tugas mengatur persiapan sebelum merekam: menyiapkan mikrofon atau perangkat, memilih ruangan yang relatif tenang, mengatur posisi mikrofon dan *recording level*, melakukan *test recording*, dan memeriksa hasil *test*. Pada tahap perekaman, penutur diberi *prompt* topik, bukan dialog yang harus dibaca, dan dibiarkan berbicara secara natural. Rancangan kelompok menyebut hasilnya sebagai *spontaneous speech* dari elisitasi *prompt*. Segmen

percakapan, yaitu tanya jawab dengan perekam atau antarpenutur, diperbolehkan dan wajib diberi label.

Informasi pelaksanaan yang dapat dipastikan dari berkas yang tersedia dirangkum pada Tabel 3.1. Setiap penutur memiliki satu rekaman utuh berdurasi 10,00–11,69 menit, dan metadata mencatat empat topik pada rekaman tersebut. Anotasi S02 mencatat 12 segmen berlabel penutur membacakan pertanyaan panduan, dan catatan QC untuk S09 menyebut bahwa penutur membaca pertanyaan terlebih dahulu sebelum menjawab. Kedua catatan ini menunjukkan bahwa *prompt* pada rekaman tersebut berbentuk pertanyaan.

Tabel 3.1. Informasi proses perekaman yang tersedia

Aspek	**Informasi yang tersedia**	**Status**
Lingkungan	*Indoor* pada 10 dari 10 baris metadata	Tersedia
Topik	Perkenalan, Keluarga, Aktivitas sehari-hari, Makanan (metadata.csv)	Tersedia
Perangkat, mikrofon, dan aplikasi perekam	Tidak ada pada berkas yang tersedia	Perlu dikonfirmasi
Lokasi atau ruangan	Tidak ada pada berkas yang tersedia	Perlu dikonfirmasi
Tanggal rekaman dan anggota perekam	Tidak ada pada berkas yang tersedia	Perlu dikonfirmasi
Posisi mikrofon, *recording level*, dan *test recording*	Tidak ada pada berkas yang tersedia	Perlu dikonfirmasi
Teks *prompt* yang digunakan	Tidak ada pada berkas yang tersedia	Perlu dikonfirmasi
Jenis ucapan (*spontaneous* atau *conversation*)	Tidak dicatat per rekaman	Perlu dikonfirmasi
Sampling rate asli rekaman	Tidak dicatat; berkas akhir bersampling rate 16 kHz	Perlu dikonfirmasi

Informasi berstatus “perlu dikonfirmasi” belum terdokumentasi, sehingga laporan ini tidak menguraikan prosedur perekaman aktual lebih jauh.

3.3. Pengelolaan Berkas Audio

Berkas audio diberi nama dengan pola Sxx_Txx_nnn.wav. Sxx adalah Speaker ID, Txx adalah kode topik, dan nnn adalah nomor urut berkas. Kesepuluh berkas

yang ada memakai pola Sxx_T01_001.wav, misalnya S01_T01_001.wav dan S05_T01_001.wav. Setiap berkas disimpan pada folder audio/Sxx dengan Speaker ID yang sama dengan awalan nama berkas, dan setiap folder berisi satu berkas WAV.

Metadata, anotasi, dan dokumentasi disimpan terpisah dari audio. Tabel 3.2 merangkum isi tiap lokasi saat ini. Berkas hasil QC, qc_report.csv, berada di folder qc, sedangkan rancangan kelompok menempatkannya di folder documentation.

Tabel 3.2. Isi folder korpus saat ini

Lokasi	Isi saat ini
audio/S01 sampai audio/S10	Masing-masing satu berkas WAV (Sxx_T01_001.wav), total 10 berkas
metadata/metadata.csv	10 baris, satu per berkas WAV
annotation/annotation-semua.csv	2.188 baris untuk 10 berkas (Subbab 4.3)
qc/qc_report.csv	10 baris dengan kolom File, Quality, Problem
documentation/	README.txt (kosong) dan berkas laporan

Seluruh berkas dikelola pada repositori GitHub kelompok yang disebut pada Subbab 1.2. Dokumentasi pengolahan audio, misalnya apakah rekaman dikonversi dari master atau dipotong dari rekaman sesi, tidak tersedia dan perlu dikonfirmasi.

4. Hasil dan Quality Control

4.1. Hasil Pengumpulan Rekaman

Rancangan korpus mencakup 10 penutur (S01–S10). Sampai laporan ini disusun, audio, metadata, dan label kualitas tersedia untuk kesepuluh penutur. Jumlah penutur yang memiliki data sama dengan jumlah yang direncanakan.

Setiap penutur memiliki satu berkas WAV, sehingga korpus saat ini terdiri atas sepuluh berkas. Tabel 4.1 menyajikan durasi tiap berkas sesuai kolom Duration pada metadata.csv.

Tabel 4.1. Berkas rekaman dan durasi

Speaker	Gender	Berkas	Durasi (detik)	Durasi (menit)
S01	M	S01_T01_001.wav	629,76	10,50
S02	M	S02_T01_001.wav	701,67	11,69
S03	M	S03_T01_001.wav	643,24	10,72
S04	M	S04_T01_001.wav	701,18	11,69
S05	M	S05_T01_001.wav	601,45	10,02
S06	F	S06_T01_001.wav	690,94	11,52
S07	F	S07_T01_001.wav	651,16	10,85
S08	F	S08_T01_001.wav	607,77	10,13
S09	F	S09_T01_001.wav	600,00	10,00
S10	F	S10_T01_001.wav	689,60	11,49
Total (10 berkas)			**6.516,77**	**108,61**

Total durasi sepuluh berkas adalah 6.516,77 detik atau 108,61 menit, dengan rata-rata 10,86 menit per penutur. Berkas terpendek adalah S09 (600,00 detik) dan terpanjang adalah S02 (701,67 detik). Total durasi sepuluh berkas berada dalam kisaran 100–150 menit yang dirancang, dan seluruh berkas berdurasi minimal 10 menit. Namun, angka tersebut adalah durasi berkas yang masih mencakup jeda, sedangkan durasi ucapan bersih belum diukur kecuali gambaran untuk S09 pada Subbab 4.2. Total lima penutur laki-laki adalah 3.277,30 detik (54,62 menit) dan total lima penutur perempuan 3.239,47 detik (53,99 menit), dengan selisih 37,83 detik atau sekitar 1,2%.

Menurut topik, keempat topik yang tercatat pada metadata (Perkenalan, Keluarga, Aktivitas sehari-hari, dan Makanan) muncul pada 10 dari 10 baris metadata. Setiap penutur hanya memiliki satu berkas yang memuat seluruh topik, dan metadata tidak mencatat posisi awal dan akhir tiap topik. Durasi per topik karenanya tidak dapat dihitung dari metadata. Berkas anotasi mencatat waktu mulai dan selesai tiap segmen beserta label topiknya, tetapi labelnya tidak sama dengan topik pada metadata (Subbab 2.3).

4.2. Dokumentasi Hasil Quality Control

Rekapitulasi QC bersumber dari berkas qc_report.csv. Berkas ini berisi sepuluh baris dengan kolom File, Quality, dan Problem, sesuai dengan sepuluh baris pada metadata.csv, dan label Quality pada kedua berkas identik untuk setiap rekaman. Tabel 4.2 menyajikan isi qc_report.csv sebagaimana tercatat.

Sesuai spesifikasi tugas, setiap rekaman diperiksa berdasarkan tujuh kriteria: (1) suara terdengar jelas, (2) tidak terjadi *clipping*, (3) *noise* masih dapat diterima, (4) tidak ada suara orang lain yang mengganggu, (5) rekaman tidak terpotong, (6) format sesuai, dan (7) metadata lengkap. Hasilnya dinyatakan dengan tiga label. Good berarti suara jelas dan dapat digunakan tanpa masalah berarti. Acceptable berarti ada gangguan kecil tetapi suara masih dapat digunakan. Reject berarti ada masalah serius, dan rekaman diulang jika memungkinkan. Definisi tiga label ini mengikuti materi kuliah.

Tabel 4.2. Isi qc_report.csv

File	Quality	Problem
S01_T01_001.wav	Good	-
S02_T01_001.wav	Good	-
S03_T01_001.wav	Acceptable	Background noise cukup tinggi namun ucapan masih dapat dipahami
S04_T01_001.wav	Good	-
S05_T01_001.wav	Good	-
S06_T01_001.wav	Good	-
S07_T01_001.wav	Good	-
S08_T01_001.wav	Good	-
S09_T01_001.wav	Acceptable	Silence digital berulang: sekitar 14 jeda sepanjang 10 sampai 14 detik (sekitar 39% durasi), karena penutur berpikir dan membaca pertanyaan terlebih dahulu
S10_T01_001.wav	Good	-

Tabel 4.3. Rekapitulasi hasil QC

Kategori	Jumlah	Berkas
Good	8	S01, S02, S04, S05, S06, S07, S08, S10
Acceptable	2	S03, S09
Reject	0	Tidak ada
Belum diperiksa	0	Tidak ada
Total berkas diperiksa	**10**	

Dari sepuluh rekaman yang diperiksa, delapan berlabel Good, dua berlabel Acceptable, dan tidak ada yang berlabel Reject. Seluruh berkas memiliki label, sehingga tidak ada rekaman yang belum diperiksa. Dengan label saat ini, tidak ada rekaman yang memerlukan perekaman ulang.

Dua rekaman Acceptable memiliki masalah yang berbeda. S03 mengandung *background noise* yang cukup tinggi, tetapi ucapan masih dapat dipahami. S09 mengandung *silence* digital berulang. Pengukuran menemukan 14 segmen senyap digital (amplitudo sampel ≤ 1) berdurasi minimal 1 detik: satu segmen 3,3 detik di awal rekaman dan 13 segmen berdurasi 10,7–14,6 detik. Totalnya 170,2 detik atau 28,4% dari 600,00 detik, sehingga jumlah dan panjang jeda sesuai dengan catatan QC. Anotasi S09 juga menandai 18 baris dengan penanda hening digital.

Persentase pada catatan QC (sekitar 39%) lebih besar daripada porsi senyap digital murni tersebut. Angka itu mendekati proporsi bingkai berdurasi 25 milidetik dengan tingkat sinyal di bawah −60 dBFS, yaitu 243,2 detik atau 40,5%. Catatan QC kemungkinan menghitung juga bagian yang sangat pelan selain senyap digital, tetapi metodenya belum terdokumentasi. Durasi di luar senyap digital adalah sekitar 429,8 detik (7,2 menit), dan durasi di luar bingkai di bawah −60 dBFS sekitar 356,8 detik (5,9 menit). Menurut kedua ukuran, durasi berisi sinyal pada S09 berada di bawah 10 menit, padahal rancangan kelompok menargetkan ucapan bersih 10–15 menit per penutur.

qc_report.csv hanya mencatat label akhir dan masalah per berkas. Berkas ini tidak memuat hasil per kriteria, nama pemeriksa, tanggal pemeriksaan, maupun tindakan lanjutan. Laporan ini karenanya tidak dapat menyatakan hasil tiap kriteria untuk rekaman berlabel Good, selain bahwa tidak ada masalah yang dicatat. Cara pemeriksaan, misalnya apakah rekaman didengarkan langsung, perlu dikonfirmasi kelompok.

Sebagai pelengkap, dilakukan pemeriksaan teknis otomatis terhadap nilai puncak (*peak*) sampel pada kesepuluh berkas (Tabel 4.4). Pada S01 terdapat 25 sampel dan pada S09 terdapat 2 sampel yang mencapai nilai maksimum 16-bit, dan *peak* S04, S06, S07, S08, serta S10 berada antara −0,6 dan −0,1 dBFS. Pada S05 *peak* berada di −1,0 dBFS, tanpa sampel pada nilai maksimum dan tanpa segmen senyap digital berdurasi minimal 1 detik, sehingga pengukuran ini tidak bertentangan dengan label Good pada S05. Metrik ini hanya menjadi penanda untuk didengar ulang. Ada atau tidaknya distorsi pada berkas tersebut belum diperiksa melalui pendengaran, sehingga label pada Tabel 4.2 dipertahankan sebagaimana tercatat dan belum dapat dikonfirmasi oleh pengukuran ini. Perubahan label hanya dilakukan setelah anggota kelompok mendengar ulang rekaman terkait.

Tabel 4.4. *Peak* sampel dan jumlah sampel pada nilai maksimum

File	*Peak* (dBFS)	Sampel pada nilai maksimum
S01_T01_001.wav	0,0	25
S02_T01_001.wav	−3,1	0
S03_T01_001.wav	−4,2	0
S04_T01_001.wav	−0,3	0
S05_T01_001.wav	−1,0	0
S06_T01_001.wav	−0,2	0
S07_T01_001.wav	−0,1	0
S08_T01_001.wav	−0,6	0
S09_T01_001.wav	0,0	2

File	*Peak* (dBFS)	Sampel pada nilai maksimum
S10_T01_001.wav	−0,5	0

4.3. Hasil Anotasi dan Review

Anotasi tersedia dalam berkas annotation-semua.csv. Berkas ini memuat 2.188 baris segmen untuk kesepuluh berkas audio, termasuk S05. Dari jumlah itu, 2.168 baris berisi transkripsi dan 20 baris bertanda -gap pada segment_id tidak berisi transkripsi (S02 8 baris, S03 2, S06 1, S08 3, dan S09 6). Baris tanpa transkripsi mencatat jeda panjang, hening digital, atau ucapan yang tidak tertranskripsi oleh ASR. Total durasi segmen bertranskripsi adalah 5.738,32 detik (95,64 menit). Dengan tokenisasi sederhana berdasarkan rangkaian huruf, transkripsi memuat 12.646 token dan 2.590 kosakata berbeda. Pada S09, 119,5 detik senyap digital berada di dalam rentang waktu segmen bertranskripsi, sehingga durasi bertranskripsi S09 melebihi durasi ucapan sebenarnya. Tabel 4.5 merangkum anotasi per berkas.

Tabel 4.5. Rekapitulasi anotasi per berkas

Speaker	Baris	Bertranskripsi	Durasi bertranskripsi (detik)	Rata-rata confidence_asr	Durasi berlabel Jawa (%)
S01	112	112	592,95	0,881	95,9
S02	222	214	530,40	0,865	59,6
S03	370	368	509,34	0,889	91,3
S04	301	301	575,83	0,884	93,2
S05	106	106	566,44	0,825	93,6
S06	70	69	659,25	0,875	72,2
S07	527	527	649,84	-	86,0
S08	80	77	561,95	0,859	41,7
S09	73	67	508,23	0,875	76,9
S10	327	327	584,09	0,918	92,3
Total	**2.188**	**2.168**	**5.738,32**	**0,884**	**80,4**

Label bahasa pada segmen bertranskripsi menunjukkan bahwa tidak seluruh ucapan berbahasa Jawa. Segmen berlabel Jawa berjumlah 1.861 dengan durasi 4.615,7 detik (80,4%). Segmen campuran Jawa–Indonesia, Jawa–Inggris, dan Jawa–Indonesia–Inggris berdurasi 796,5 detik (13,9%), segmen berbahasa Indonesia 303,2 detik (5,3%), dan segmen berbahasa Inggris 22,9 detik (0,4%). Porsi durasi berlabel Jawa berbeda jauh antarpenutur, dari 41,7% pada S08 dan 59,6% pada S02 hingga 95,9% pada S01. Kolom label_kejadian berisi 238 baris dengan penanda selain tanda hubung, misalnya napas, filler, pengulangan, batuk, musik, dan catatan tentang ASR. Penanda ini berupa teks bebas.

Status review belum dapat dilaporkan. Berkas anotasi tidak memiliki kolom Annotator, Reviewer, maupun Status, sehingga tidak diketahui siapa yang menyusun dan memeriksa tiap baris. Kolom confidence_asr terisi pada 1.641 baris dengan rata-rata 0,884, dan sebagian catatan kejadian menyebut ASR, misalnya ucapan yang terlewat, kalimat berulang, dan kemungkinan halusinasi. Keduanya menunjukkan bahwa transkripsi berasal dari ASR otomatis. Belum ada bukti bahwa penutur asli dalam kelompok telah memeriksa transkripsi tersebut, sehingga seluruh transkripsi diperlakukan sebagai draf. Kolom confidence_asr kosong pada seluruh 527 baris S07 dan pada 20 baris tanpa transkripsi, dan label speaker S07 diberi catatan tanpa verifikasi akustik.

Dengan demikian anotasi sudah mencakup transkripsi, label speaker, label bahasa, label dialek, label topik, dan label kejadian untuk kesepuluh berkas, tetapi tahap *review* dan perbaikan menuju *final annotation* belum terdokumentasi. Struktur berkas juga berbeda dari rancangan kelompok, dan label topiknya perlu diselaraskan dengan topik pada metadata.

5. Penutup

5.1. Kesimpulan

Laporan ini mendokumentasikan pengumpulan korpus suara Bahasa Jawa pada Fase 1 IF4071, yang ditujukan sebagai data sistem pengenal ucapan pada Fase 2. Rancangan korpus mengikuti spesifikasi tugas: 10 penutur (5 laki-laki dan 5 perempuan), ucapan spontan berbasis *prompt* topik, serta format WAV 16 kHz, 16-bit, mono. Sampai laporan ini disusun, rekaman audio tersedia untuk kesepuluh penutur (S01–S10), dengan total durasi 6.516,77 detik (108,61 menit) dan format yang sesuai spesifikasi menurut ffprobe. Menurut metadata, komposisi penutur adalah 5 laki-laki dan 5 perempuan. Korpus memuat lebih dari satu dialek, dan tiga penutur (S03, S05, S09) diberi label non-asli atau warisan.

Hasil QC mencakup kesepuluh rekaman. Berdasarkan qc_report.csv, delapan rekaman berlabel Good, dua rekaman (S03 dan S09) berlabel Acceptable, dan tidak ada yang berlabel Reject. Label tersebut belum disertai hasil per kriteria, dan pemeriksaan teknis tambahan menemukan *peak* mendekati 0 dBFS pada sejumlah berkas, termasuk yang berlabel Good, sehingga berkas-berkas itu perlu didengar ulang. Pada S09, *silence* digital membuat durasi berisi sinyal berada di bawah 10 menit.

Korpus belum dapat dinyatakan lengkap. Anotasi sudah mencakup 2.188 baris untuk kesepuluh berkas, tetapi transkripsinya berasal dari ASR dan belum terdokumentasi sebagai hasil *review*. README korpus belum terisi, dan daerah asal serta rentang usia penutur belum terdokumentasi. Walaupun tidak ada rekaman berlabel Reject, cara pemeriksaan label belum terdokumentasi dan sejumlah berkas perlu didengar ulang (Subbab 4.2).

REFERENSI

Lestari, D. (2026). *Feature Extraction: Mel Feature Cepstrum Coeffiicent* [Slide kuliah]. IF4071 Pemrosesan Ucapan, Institut Teknologi Bandung.

Hoesen, D. (2026). Rekayasa Fitur Ucapan [Slide kuliah]. IF4071 Pemrosesan Ucapan, Institut Teknologi Bandung.

Lestari, D. (2026). *Automatic Speech Recognition: Template Vektor dan Model Gaussian* [Slide kuliah]. IF4071 Pemrosesan Ucapan, Institut Teknologi Bandung.

FFmpeg Developers. (n.d.). *ffprobe documentation*. https://ffmpeg.org/ffprobe.html

International Organization for Standardization. (2002). *ISO 639-1:2002 Codes for the representation of names of languages: Part 1: Alpha-2 code*. ISO. https://www.loc.gov/standards/iso639-2/php/code_list.php

Novitasari, S., Tjandra, A., Sakti, S., & Nakamura, S. (2020). Cross-lingual machine speech chain for Javanese, Sundanese, Balinese, and Bataks speech recognition and synthesis. *Proceedings of the 1st Joint Workshop on Spoken Language Technologies for Under-resourced Languages (SLTU) and Collaboration and Computing for Under-Resourced Languages (CCURL)*. European Language Resources Association.

Wibawa, J. A. E., Sarin, S., Li, C., Pipatsrisawat, K., Sodimana, K., Kjartansson, O., Gutkin, A., Jansche, M., & Ha, L. (2018). Building open Javanese and Sundanese corpora for multilingual text-to-speech. *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*. European Language Resources Association. https://aclanthology.org/L18-1255

Arisaputra, P., Handoyo, A. T., & Zahra, A. (2024). XLS-R deep learning model for multilingual ASR on low-resource languages: Indonesian, Javanese, and Sundanese. Bina Nusantara University.